

La variance empirique et la distribution khi-deux

Antonio Falcó

14/11/2019

Questions à répondre

- Sous l'hypothèse que la variable `taille` suit une distribution normale, est-ce qu'on peut calculer l'erreur commise en prenant `var(nutriage$taille)` comme une approximation de la variance de la taille σ^2 chez la population?
- Est-ce qu'on peut trouver un intervalle $[a, b]$ tel que la probabilité de trouver la variance σ^2 à l'intervalle $[a, b]$ soit égal à $1 - \alpha$?

```
nutriage <- read.csv("~/Descargas/Atelier4-master(2)/Atelier4-master/nutriage.csv")
names(nutriage)
```

```
## [1] "sexe"           "situation"       "the"
## [4] "cafe"           "taille"          "poids"
## [7] "age"            "viande"          "poisson"
## [10] "fruit_crus"     "fruit_legume_cuits" "chocol"
## [13] "matgras"
```

```
mu <- mean(nutriage$taille)
sigma2 <- var(nutriage$taille)
n <- length(nutriage$taille)
mu
```

```
## [1] 163.9602
```

```
sigma2
```

```
## [1] 81.06063
```

```
n
```

```
## [1] 226
```

Reponse

On connaît que

$$\frac{(n-1)S^2}{\sigma^2} \sim \chi_{n-1}^2$$

ou

$$S^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2 = \text{var}(X)$$

Soit $\varepsilon > 0$ l'erreur d'approximation entre S^2 et la vraie valeur chez la population σ^2 :

$$|S^2 - \sigma^2| < \varepsilon$$

Alors fixée une probabilité $1 - \alpha$ pour l'erreur ε on a la suivante expression pour l'erreur d'approximation:

$$\Pr(|S^2 - \sigma^2| < \varepsilon) = 1 - \alpha.$$

Observe que

$$\begin{aligned}\Pr(|S^2 - \sigma^2| < \varepsilon) &= \Pr(-\varepsilon < \sigma^2 - S^2 < \varepsilon) \\ &= \Pr(-\varepsilon + S^2 < \sigma^2 < \varepsilon + S^2) \\ &= \Pr\left(\frac{(-\varepsilon + S^2)}{(n-1)S^2} < \frac{\sigma^2}{(n-1)S^2} < \frac{(\varepsilon + S^2)}{(n-1)S^2}\right) \\ &= \Pr\left(\frac{(n-1)S^2}{(\varepsilon + S^2)} < \frac{(n-1)S^2}{\sigma^2} < \frac{(n-1)S^2}{(-\varepsilon + S^2)}\right)\end{aligned}$$

on peut conclure:

$$\Pr\left(\frac{(n-1)S^2}{(\varepsilon + S^2)} < \chi_{n-1}^2 < \frac{(n-1)S^2}{(-\varepsilon + S^2)}\right) = 1 - \alpha.$$

Soit

$$\begin{aligned}x_{\min} &= \frac{(n-1)S^2}{S^2 + \varepsilon} \Leftrightarrow \varepsilon = \frac{(n-1)S^2}{x_{\min}} - S^2 \\ x_{\max} &= \frac{(n-1)S^2}{S^2 - \varepsilon} \Leftrightarrow \varepsilon = S^2 - \frac{(n-1)S^2}{x_{\max}}\end{aligned}$$

Observe qu'il se vérifie que

$$S^2 - \frac{(n-1)S^2}{x_{\max}} = \frac{(n-1)S^2}{x_{\min}} - S^2 \Leftrightarrow 2S^2 = \frac{(n-1)S^2}{x_{\max}} + \frac{(n-1)S^2}{x_{\min}}$$

et

$$2 = \frac{(n-1)}{x_{\max}} + \frac{(n-1)}{x_{\min}} \Leftrightarrow \frac{2}{n-1} = \frac{1}{x_{\min}} + \frac{1}{x_{\max}}$$

Si on prend l'expression

$$\Pr(x_{\min} < \chi_{n-1}^2 < x_{\max}) = 1 - \alpha.$$

on peut déduire que

$$x_{\max} = \text{qchisq}(1 - \frac{\alpha}{2}, n-1) \text{ et } x_{\min} = \text{qchisq}(\frac{\alpha}{2}, n-1)$$

On obtient finalement les formules suivantes:

$$\text{qchisq}(\frac{\alpha}{2}, n-1) = \frac{(n-1)S^2}{S^2 + \varepsilon}$$

et

$$\text{qchisq}(1 - \frac{\alpha}{2}, n-1) = \frac{(n-1)S^2}{S^2 - \varepsilon}$$

On va résoudre le cas pratique suivant: On supposant que $\alpha = 0.05$ chercher ε tel que

$$\Pr(|S^2 - \sigma^2| < \varepsilon) = 0.95.$$

Pour la variable `taille` on connaît que $S^2 = 81.06063$ et $n - 1 = 225$. Si on calcule x_{\min} et x_{\max} :

```
alpha = 0.05
xmin <- qchisq(alpha/2, (length(nutriage$taille)-1))
xmax <- qchisq(1-alpha/2, (length(nutriage$taille)-1))
xmin
```

```
## [1] 185.3483
```

```
xmax
```

```
## [1] 268.4378
```

On va vérifier l'expression

$$\frac{2}{n-1} = \frac{1}{x_{\min}} + \frac{1}{x_{\max}}$$

avec le logiciel:

```
(1/xmin)+(1/xmax)
```

```
## [1] 0.009120504
```

```
2/(n-1)
```

```
## [1] 0.008888889
```

En utilisant l'équation:

$$\varepsilon = S^2 - \frac{(n-1)S^2}{x_{\max}} \Leftrightarrow S^2 - \epsilon = \frac{(n-1)S^2}{x_{\max}} \Leftrightarrow \epsilon = S^2 - \frac{(n-1)S^2}{x_{\max}}$$

on peut calculer l'erreur d'approximation à 95% de proba:

```
epsilon <- var(nutriage$taille)-(length(nutriage$taille)-1)*var(nutriage$taille)/xmax  
epsilon
```

```
## [1] 13.117
```

et on obtient un erreur de $\varepsilon = 13.117$.

Comme on peut conclure que

$$\Pr(|S^2 - \sigma^2| < 13.117) = 0.95$$

c'est-à-dire

$$\Pr(-13.117 < S^2 - \sigma^2 < 13.117) = 0.95,$$

qui est équivalent à

$$\Pr(-13.117 + S^2 < \sigma^2 < 13.117 + S^2) = 0.95$$

ou $-13.117 + S^2 < \sigma^2$ est égal à

```
var(nutriage$taille)-epsilon
```

```
## [1] 67.94363
```

et $13.117 + S^2 < \sigma^2$ est égal à

```
var(nutriage$taille)+epsilon
```

```
## [1] 94.17763
```

Alors

$$\Pr(67.94363 < \sigma^2 < 94.17763) = 0.95$$

la variance de la `taille`, chez la population σ^2 , est à l'intervalle $[67.94363, 94.17763]$ avec une probabilité de 95%.